

Filmajánló rendszer kollaboratív szűréssel

Kónya Tamás Ádám
konyatomi16@stud.uni-obuda.hu
B6EHWG

Absztrakt – Az ajánlórendszerek kulcsszerepet játszanak a modern online szolgáltatásokban, mivel segítik a felhasználókat a releváns tartalmak megtalálásában nagy adathalmazokban. Jelen kutatás célja a kollaboratív szűrésen alapuló filmajánló rendszerek teljesítményének vizsgálata. A tanulmány a felhasználó-alapú és az elem-alapú kollaboratív szűrési módszereket hasonlítja össze a MovieLens (ml-latest-small) adatkészlet felhasználásával, amely több mint 100 000 értékelést tartalmaz. A rendszert Python nyelven implementáltuk, ahol a hasonlóság számítása Pearson-korrelációval, az előrejelzés pedig szomszédsági alapú módszerrel történik. A modellek teljesítményét előrejelzési pontosság (RMSE, MAE) és ajánlási minőség (Precision@10, Recall@10) alapján értékeltük különböző tanító-teszt felosztások mellett. Az eredmények azt mutatják, hogy a felhasználó-alapú módszer minden metrika esetén felülmúlja az elem-alapú megközelítést, a legjobb eredményt a 75/25 felosztás mellett érve el (RMSE = 0,970; MAE = 0,749). Továbbá megfigyelhető, hogy a nagyobb tanítóhalmaz javítja a visszahívási értékeket. Az eredmények alapján a felhasználó-alapú kollaboratív szűrés hatékonyabb megoldást nyújt a vizsgált környezetben, valamint rámutat a tanító-teszt arány jelentőségére az ajánlórendszerek teljesítményében.

Kulcsszavak – ajánlórendszer, kollaboratív szűrés, felhasználó-alapú szűrés, elem-alapú szűrés, MovieLens, gépi tanulás, RMSE, MAE, Precision@k, Recall@k

I. BEVEZETÉS

Az online szolgáltatások működésében napjainkban kiemelten fontos szerepet töltenek be az ajánlórendszerek, mivel ezek segítik a felhasználókat abban, hogy a hatalmas információ-tömegben rátaláljanak a számukra releváns tartalmakra. A filmajánló rendszerek egyik leggyakrabban alkalmazott és jól bevált megközelítése a kollaboratív szűrés. Ez a módszer a felhasználók viselkedési adataira és értékeléseire támaszkodik az ajánlások generálása során. A technológia alapvető felvetése, hogy a hasonló preferenciákkal rendelkező felhasználók nagy valószínűséggel hasonló filmeket fognak kedvelni a jövőben is.

Bár a kollaboratív szűrés széles körben alkalmazott, a kutatások rámutatnak a módszer bizonyos korlátjaira is, mint például az adatok ritkaságára (data sparsity) és az úgynevezett hidegindítási (cold-start) problémára. Ezek a tényezők jelentősen csökkenthetik az ajánlások pontosságát, különösképpen új felhasználók felbukkanása vagy újonnan hozzáadott tartalmak esetén. Bár a szakirodalom számos fejlett megközelítést, például hibrid rendszereket [2], mély megerősítéses tanulást [3], vagy K-közép klaszterezést [4] javasol ezen problémák enyhítésére, az alapvető kollaboratív szűrési technikák megfelelő kiválasztása és optimalizálása továbbra is elengedhetetlen a hatékony rendszerek építéséhez.

Jelen kutatás fő célja egy filmajánló rendszer átfogó vizsgálata, amelynek során különböző kollaboratív szűrési módszereket alkalmazunk és hasonlítunk össze. A kísérlet specifikusan a felhasználó-alapú (user-based) és az elem-alapú (item-based) kollaboratív szűrési technikák teljesítményét állítja szembe egymással. A rendszer a több

mint százezer értékelést tartalmazó MovieLens (ml-latest-small) adatkészlet alapján dolgozik, az eredményeket pedig szigorú metrikákkal - az előrejelzési pontosságot RMSE és MAE, míg az ajánlások minőségét Precision@k és Recall@k értékekkel - elemezzük.

A tanulmány felépítése a következő: A II. fejezet (Szakirodalmi áttekintés) áttekinti az ajánlórendszerekhez és a kollaboratív szűréshez kapcsolódó releváns szakirodalmat és a terület eddigi kutatási irányait. A III. fejezet (Módszertan) részletesen bemutatja az alkalmazott adatkészletet, az adatfeldolgozás folyamatát, a vizsgált algoritmusokat, valamint a kiértékelési metrikákat. A IV. fejezet (Eredmények) ismerteti a kísérletek kvantitatív eredményeit, és összehasonlítja a vizsgált módszerek eredményét. Végül az V. fejezet (Konklúzió) összefoglalja a kutatás főbb eredményeit, értelmezi azok jelentőségét, valamint ismerteti a kutatás korlátait és a lehetséges jövőbeni kutatási irányokat.

II. SZAKIRODALMI ÁTTEKINTÉS

Az ajánlórendszerek napjainkban fontos szerepet töltenek be az online szolgáltatások működésében, mivel segítenek a felhasználóknak releváns tartalmakat találni nagy mennyiségű információ között. A filmajánló rendszerek egyik leggyakrabban alkalmazott megközelítése a kollaboratív szűrés, amely a felhasználók viselkedési adatai és értékelései alapján generál ajánlásokat. A módszer alapja, hogy a hasonló preferenciákkal rendelkező felhasználók nagy valószínűséggel hasonló filmeket fognak kedvelni.

A kutatások szerint a filmajánló rendszerek különböző megközelítéseket alkalmaznak a felhasználói preferenciák modellezésére. Goyani és Chaurasiya áttekintő tanulmánya bemutatja, hogy az ajánlórendszerek gyakran kollaboratív szűrésen vagy tartalom-alapú módszereken alapulnak, illetve ezek kombinációját alkalmazzák a hatékonyabb ajánlások érdekében [1]. A kollaboratív szűrés különösen elterjedt olyan platformokon, amelyek nagymennyiségű felhasználói értékelést tartalmaznak.

Egyes kutatások azonban rámutatnak a kollaboratív szűrés korlátjaira is, például az úgynevezett cold-start problémára és az adatok ritkaságára. Ezek a problémák csökkenthetik az ajánlások pontosságát, különösen új felhasználók vagy új tartalmak esetén. Widayanti és munkatársai egy hibrid megközelítést javasolnak, amely a kollaboratív és a tartalom-alapú szűrést kombinálja annak érdekében, hogy javítsa az ajánlórendszerek teljesítményét és növeli az ajánlások pontosságát [2]. Az ilyen módszerek segíthetnek az ajánlórendszerek hatékonyságának növelésében, miközben csökkentik a hagyományos módszerek korlátait.

Az ajánlórendszerek tipikus kihívásait, köztük a cold-start problémát és az adatritkaságot már Adomavicius és Tuzhilin [10] is részletesen elemezték alpművükben. Tanulmányuk átfogó képet ad a kollaboratív és tartalom-alapú szűrés hatásairól, és már korán lefektette a hibrid megközelítések, valamint a kontextustudatos ajánlások elméleti alapjait, amelyek ma is meghatározzák a kutatási irányokat.

A hagyományos kollaboratív szűrés hiányosságainak, mint például az adatritkaság (data sparsity) és a cold-start probléma kezelésére további fejlett megoldások is születtek. Peng és szerzőtársai [3] egy innovatív rendszert javasolnak, amely a mély megerősítéses tanulást, DRL (Deep Reinforcement Learning), és a kollaboratív szűrést integrálja. Megközelítésük az "actorcritic" módszert és a DDPG algoritmust alkalmazza a kezdeti ajánlások megtételéhez az új felhasználók számára, míg a részletesebb jellemzők kinyerésére szinguláris értékfelbontást, SVD (Singular Value Decomposition), használnak a mátrixfaktorizáció során. Egy másik irányvonalat képvisel Phorasis és Yu [4] kutatása, akik a kollaboratív szűrést a K-közép (Kmeans) klaszterezési algoritmussal ötvözték. Az ő módszerük a felhasználókat érdeklődési körük alapján dimenziós terekben csoportosítja, ami a hagyományos kollaboratív szűréshez képest nemcsak a pontosságot növeli, de a számítási időt is jelentősen csökkenti.

A kollaboratív szűrés klasszikus szomszédsági (neighborhood) megközelítései közül a felhasználó-alapú módszerek mellett kiemelt jelentőségű az elem-alapú (item-based) technika, amelyet Sarwar és munkatársai [8] vezettek be. Ez a megközelítés a felhasználók helyett az elemek (filmek) közötti hasonlóságokra fókuszál, ami nagy adatbázisok esetén jelentős skálázhatósági és számítási előnyöket kínál, így gyakran szolgál robosztus alapmodellként (baseline) az összehasonlító elemzésekben.

A kollaboratív szűrés fejlesztése két irányban folytatódott. Dev és Mohan [5] a skálázhatóságra koncentráltak, amely sok számítógépen osztja szét a munkát, így a kollaboratív szűrés nagy adatbázisok esetén is gyors marad [5].

Katarya és Verma [6] ezzel szemben a pontosság javítására összpontosítottak. Három technikát kombináltak: aszimmetrikus hasonlóságszámítást, mátrixfaktorizációt és tipikalitás-alapú szűrést. Az aszimmetrikus hasonlóság felismeri, hogy a hasonlóság nem feltétlenül kölcsönös, ami pontosabban tükrözi a valós felhasználói kapcsolatokat [6]. A mátrixfaktorizáció rejtett mintázatokat tár fel az adatokban, míg a tipikalitás-alapú módszer műfajok szerint csoportosítja a filmeket, ami különösen ritka adatok esetén javítja az előrejelzések pontosságát [6].

A látens jellemzők kinyerése terén a modell-alapú kollaboratív szűrés, különösen a mátrixfaktorizáció hozott jelentős áttörést. Ahogy azt Koren és szerzőtársai [9] demonstrálták, a felhasználó-elem interakciók alacsonyabb dimenziós térbe történő leképezése rendkívül hatékonyan képes kezelni az adatritkaságot, és finomhangolt, pontos ajánlásokat eredményez a rejtett preferenciák feltérképezésével.

Míg Dev és Mohan [5] a gyorsaságra és a nagy adathalmazok kezelésére fókuszáltak, addig Katarya és Verma [6] a pontosabb előrejelzésekre koncentráltak. A két megközelítés kombinációja ígéretes irány lehet a jövőbeni kutatások számára, hiszen egy olyan rendszer, amely egyszerre gyors és pontos, ideális választás lehet valós alkalmazásokhoz.

III. MÓDSZERTAN

A kutatás célja egy filmajánló rendszer vizsgálata különböző kollaboratív szűrési módszerek alkalmazásával. A rendszer a felhasználók korábbi filmértékelései alapján generál ajánlásokat, majd az ajánlások minőségét különböző kiértékelési metrikák segítségével elemizzük.

A kísérlethez a MovieLens adatkészletet használjuk, azon belül az ml-latest-small változatot. Az adatkészlet több mint százezer filmértékelést tartalmaz, amelyek felhasználók és filmek közötti interakciókat írnak le. Az adatok felhasználóazonosítót, filmazonosítót és értékelési pontszámokat tartalmaznak, amelyek alapján felépíthető a felhasználó-film értékelési mátrix.

A rendszer implementációja Python programozási nyelven történik. Az adatok feldolgozásához a Pandas könyvtárat használjuk, amely lehetővé teszi a CSV fájlok betöltését és DataFrame struktúrába történő kezelését, valamint pivot tábla segítségével a felhasználó-film értékelési mátrix létrehozását. A numerikus számításokhoz és a hasonlósági értékek meghatározásához a NumPy könyvtárat alkalmazzuk. Az adatkészlet tanító és tesztelő részre történő felosztása 70/30 arányban történik a Scikit-learn könyvtár `train_test_split` függvényének segítségével.

A kutatás során két kollaboratív szűrési módszert hasonlítunk össze: felhasználó-alapú és elem-alapú kollaboratív szűrést. Mindkét módszerben a felhasználók vagy filmek közötti hasonlóságot Pearson-korreláció segítségével számítjuk ki a NumPy `corrcoef` függvényével. A predikció során a rendszer a legközelebbi szomszédok értékeléseit veszi figyelembe, és ezek súlyozott átlagából becsüli meg egy adott felhasználó várható értékelését egy még nem értékelt film esetében.

A rendszer teljesítményét két különböző szempont alapján értékeljük. Az előrejelzési pontosságot RMSE (Root Mean Squared Error) és MAE (Mean Absolute Error) metrikák segítségével mérjük, amelyek a prediktált és tényleges értékelések közötti eltérést vizsgálják a teszt adatokon. Az ajánlások minőségét továbbá Precision@k és Recall@k metrikákkal értékeljük, amelyek azt mérik, hogy a legjobb k ajánlás közül mennyi releváns a felhasználó számára, illetve a releváns elemek mekkora részét sikerült megtalálni. Relevánsnak azokat a filmeket tekintjük, amelyek értékelése elér egy előre meghatározott küszöböt (például 4 vagy annál magasabb).

A kutatás hatókörét bizonyos korlátozások határozzák meg. A vizsgálat nem foglalkozik tartalom-alapú ajánlórendszerekkel, nem alkalmaz deep learning modelleket, és nem cél egy teljes ajánlórendszer-platform fejlesztése. Emellett a kutatás nem tartalmaz felhasználói kísérleteket, az értékelés kizárólag a rendelkezésre álló adatkészleten végzett kísérletek eredményeire alapul.

IV. EREDMÉNYEK

A kísérletek során a kollaboratív szűrés két megközelítését, a felhasználó-alapú (user-based) és az elem-alapú (item-based) módszereket hasonlítjuk össze különböző tanító-teszt felosztások mellett. A rendszer teljesítményét az előrejelzési pontosság szempontjából RMSE (Root Mean Squared Error) és MAE (Mean Absolute Error), míg az ajánlások minősége szempontjából Precision@10 és Recall@10 metrikák segítségével értékeltük.

Az előrejelzési pontosság eredményeit az I. táblázat mutatja.

I. TÁBLÁZAT ELŐREJELZÉSI PONTOSSÁG (RMSE ÉS MAE)

Train	Módszer	RMSE	MAE
70/30	User-based	0.978530	0.754748
70/30	Item-based	0.984761	0.761577
75/25	User-based	0.970426	0.749167
75/25	Item-based	0.980674	0.759564
80/20	User-based	0.972262	0.750189
80/20	Item-based	0.983170	0.762194

Megfigyelhető, hogy minden vizsgált felosztás esetén a felhasználó-alapú módszer alacsonyabb RMSE és MAE értékeket ér el, mint az elem-alapú megközelítés. A legjobb eredményt a 75/25 arányú felosztás mellett a felhasználó-alapú módszer adja (RMSE = 0.970426, MAE = 0.749167), ami azt jelzi, hogy ez a konfiguráció biztosítja a legpontosabb értékelés-előrejelzést. Az elem-alapú módszer minden esetben magasabb hibával működik, ami gyengébb predikciós teljesítményt jelez.

Az ajánlások minőségét a Precision@10 és Recall@10 metrikák alapján a II. táblázat szemlélteti.

II. TÁBLÁZAT AJÁNLÁSOK MINŐSÉGE (PRECISION@10 ÉS RECALL@10)

Train	Módszer	Precision@10	Recall@10
70/30	User-based	0.618033	0.581367
70/30	Item-based	0.539836	0.545025
75/25	User-based	0.592131	0.622212
75/25	Item-based	0.520000	0.584486
80/20	User-based	0.555410	0.674679
80/20	Item-based	0.491475	0.639732

A Precision@10 értékek alapján a felhasználó-alapú módszer minden felosztás esetében jobban teljesít, ami azt mutatja, hogy a legjobb ajánlások között nagyobb arányban található releváns elemek. A Recall@10 esetében megfigyelhető, hogy a nagyobb tanítóhalmaz (80/20 felosztás) magasabb visszahívási értékeket eredményez, különösen a felhasználó-alapú módszer esetében (Recall@10 = 0.674679). Ez arra utal, hogy a több tanulóadat esetén a rendszer képes több releváns elemet megtalálni.

A vizsgálat során az elem-alapú kollaboratív szűrést baseline módszerként alkalmaztuk, amelyhez viszonyítva értékeltük a felhasználó-alapú megközelítést. Az eredmények alapján a felhasználó-alapú módszer minden metrika esetén felülmúlja a baseline-t, mind az előrejelzési pontosság, mind az ajánlási minőség tekintetében. Ez egyértelműen jelzi, hogy a felhasználók közötti hasonlóságon alapuló modell hatékonyabban képes megragadni a preferenciák közötti összefüggéseket.

Összességében megállapítható, hogy a felhasználó-alapú kollaboratív szűrés jobb teljesítményt nyújt az elem-alapú módszerekhez képest, különösen a predikciós hibák

csökkentése és a releváns ajánlások arányának növelése terén. A tanító és teszt adatok aránya szintén befolyásolja az eredményeket: a 75/25 felosztás a pontosság szempontjából optimálisnak bizonyult, míg a 80/20 felosztás a recall értékek maximalizálásában nyújt előnyt.

A kísérletek teljes reprodukálhatóságának biztosítása érdekében a megvalósítás és az összes futtatott kísérlet a Kaggle platformon érhető el [7]. A repository tartalmazza a felhasznált adatkészletet, a modellek implementációját, valamint az összes eredményt generáló kódot és kimenetet.

V. KONKLÚZIÓ

A kutatás célja egy filmajánló rendszer vizsgálata volt különböző kollaboratív szűrési módszerek alkalmazásával, különös tekintettel a felhasználó-alapú és az elem-alapú megközelítések összehasonlítására. Az eredmények alapján megállapítható, hogy a felhasználó-alapú kollaboratív szűrés minden vizsgált metrika esetén jobb teljesítményt nyújtott. Alacsonyabb RMSE és MAE értéket ért el, valamint magasabb Precision@10 és Recall@10 mutatókkal rendelkezett, ami pontosabb előrejelzéseket és relevánsabb ajánlásokat jelent. A legjobb predikciós eredményt a 75/25 arányú tanító-teszt felosztás biztosította, míg a nagyobb tanítóhalmaz (80/20) a visszahívási értékek növekedéséhez járult hozzá.

Az eredmények rámutatnak arra, hogy a felhasználók közötti hasonlóságon alapuló modellezés hatékonyabban képes megragadni a preferenciák közötti összefüggéseket, mint az elemek közötti hasonlóságokra építő megközelítés. Ez különösen fontos olyan rendszerek esetében, ahol a felhasználói viselkedés és értékelések meghatározó szerepet játszanak az ajánlások generálásában. A vizsgálat továbbá megerősíti, hogy az adatok felosztási aránya jelentős hatással van a rendszer teljesítményére, így annak megfelelő megválasztása kulcsfontosságú a gyakorlati alkalmazások során.

A kutatás ugyanakkor bizonyos korlátokkal rendelkezik. A vizsgálat kizárólag hagyományos kollaboratív szűrési módszerekre korlátozódott, nem tartalmazott hibrid vagy mélytanulás-alapú megközelítéseket, valamint nem vizsgálta valós felhasználói visszajelzések hatását. Emellett az értékelés egyetlen adatkészletre épült, ami korlátozhatja az eredmények általánosíthatóságát.

A jövőbeni kutatások során érdemes lehet hibrid ajánlórendszerek alkalmazását vizsgálni, amelyek kombinálják a kollaboratív és a tartalom-alapú megközelítéseket, valamint modern gépi tanulási technikát, például mátrixfaktorizációt vagy mély neurális hálózatok bevonását is megfontolni. További irány lehet több adatkészleten történő validáció, valamint valós felhasználói környezetben végzett tesztelés. Ezek a fejlesztések hozzájárulhatnak egy még pontosabb és robusztusabb ajánlórendszer kialakításához.

REFERENCES

- [1] M. Goyani and N. Chaurasiya, "A review of movie recommendation system: Limitations, survey and challenges," ELCVIA: Electronic Letters on Computer Vision and Image Analysis, vol. 19, no. 3, pp. 18–37, 2020.
- [2] R. Widayanti, M. H. R. Chakim, C. Lukita, U. Rahardja, and N. Lutfiani, "Improving Recommender Systems using Hybrid Techniques of Collaborative Filtering and Content-Based Filtering," Journal of Applied Data Sciences, vol. 4, no. 3, pp. 289–302, 2023.

- [3] S. Peng, S. Siet, S. Ilkhomjon, D.-Y. Kim, and D.-S. Park, "Integration of Deep Reinforcement Learning with Collaborative Filtering for Movie Recommendation Systems," *Appl. Sci.*, vol. 14, no. 3, p. 1155, Jan. 2024, doi: 10.3390/app14031155.
- [4] P. Phorasim and L. Yu, "Movies recommendation system using collaborative filtering and k-means," *Int. J. Adv. Comput. Res.*, vol. 7, no. 29, pp. 52-59, 2017, doi: 10.19101/IJACR.2017.729004.
- [5] A. V. Dev and A. Mohan, "Recommendation system for big data applications based on set similarity of user preferences," in *2016 International Conference on Next Generation Intelligent Systems (ICNGIS)*, Kottayam, 2016, pp. 1-6, doi: 10.1109/ICNGIS.2016.7854058.
- [6] R. Katarya and O. P. Verma, "Effective collaborative movie recommender system using asymmetric user similarity and matrix factorization," in *2016 International Conference on Computing, Communication and Automation (ICCCA)*, Noida, 2016, pp. 71-75, doi: 10.1109/CCAA.2016.7813692.
- [7] T. Kónya, "Movie Recommendation System in Kaggle," *Kaggle Notebook*, 2025. [Online]. Available: <https://www.kaggle.com/code/tamsknya/movierecommendationsystem-in-kaggle>
- [8] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl, "Item-based collaborative filtering recommendation algorithms," in *Proceedings of the 10th international conference on World Wide Web (WWW '01)*, 2001, pp. 285-295, doi: 10.1145/371920.372071.
- [9] Y. Koren, R. Bell, and C. Volinsky, "Matrix Factorization Techniques for Recommender Systems," *Computer*, vol. 42, no. 8, pp. 30-37, Aug. 2009, doi: 10.1109/MC.2009.263.
- [10] G. Adomavicius and A. Tuzhilin, "Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions," *IEEE Transactions on Knowledge and Data Engineering*, vol. 17, no. 6, pp. 734-749, June 2005, doi: 10.1109/TKDE.2005.99.