

Filmajánló rendszer kollaboratív szűréssel

Felhasználó-alapú és elem-alapú módszerek összehasonlító elemzése

Kónya Tamás Ádám
Óbudai Egyetem, 2026

Bevezetés

Miért fontosak az ajánlórendszerek?

- Az online platformokon túl sok a tartalom
- A felhasználók gyorsan szeretnének releváns filmeket találni
- A személyre szabott ajánlás növeli:
 - elégedettséget
 - platformon töltött időt
 - bevételt

Példák: Netflix, YouTube, Spotify, Amazon

Kutatási cél

A kutatás célja

Két klasszikus kollaboratív szűrési módszer összehasonlítása

Vizsgált modellek:

- User-Based kollaboratív filter
 - hasonló felhasználók alapján ajánl
- Item-Based kollaboratív filter
 - hasonló filmek alapján ajánl

Vizsgálati kérdés:

Melyik ad pontosabb és relevánsabb ajánlásokat?

Adatkészlet

MovieLens (ml-latest-small)

100 000 +
értékelés

100 +
felhasználó

1000 +
film

	123 movieId	asc title	asc genres
1	1	Toy Story (1995)	Adventure Animation Children Comedy Fantasy
2	2	Jumanji (1995)	Adventure Children Fantasy
3	3	Grumpier Old Men (1995)	Comedy Romance
4	4	Waiting to Exhale (1995)	Comedy Drama Romance
5	5	Father of the Bride Part II (1995)	Comedy
6	6	Heat (1995)	Action Crime Thriller
7	7	Sabrina (1995)	Comedy Romance
8	8	Tom and Huck (1995)	Adventure Children
9	9	Sudden Death (1995)	Action
10	10	GoldenEye (1995)	Action Adventure Thriller

movies.csv

	123 userId	123 movieId	123 rating	123 timestamp
1	1	1	4	964,982,703
2	1	3	4	964,981,247
3	1	6	4	964,982,224
4	1	47	5	964,983,815
5	1	50	5	964,982,931
6	1	70	3	964,982,400
7	1	101	5	964,980,868
8	1	110	4	964,982,176
9	1	151	5	964,984,041
10	1	157	5	964,984,100

ratings.csv

Módszertan

1. CSV betöltése
Pythonba



2. User-Movie mátrix
létrehozása



3. Hasonlóságszámítás
(Pearson-korreláció)



4. Predikció
szomszédok alapján



5. Kiértékelés
metrikákkal

Használt technológiák:

- Python
- Pandas
- NumPy
- Scikit-learn

Kiértékelési metrikák

Pontossági mutatók

Predikciós hibák:

- **RMSE** – négyzetes hiba gyöke
- **MAE** – átlagos abszolút hiba

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Ajánlási minőség:


- **Precision@10** – top10 ajánlásból mennyi releváns
- **Recall@10** – releváns filmekből mennyit talált meg

$$\text{Precision@k} = \frac{\text{Releváns találatok száma a top } k\text{-ban}}{k}$$

$$\text{Recall@k} = \frac{\text{Releváns elemek száma a top } k \text{ találatban}}{\text{Összes releváns elem száma az adatbázisban}}$$

Eredmények (RMSE, MAE)

Előrejelzési pontosság




Train	Módszer	RMSE	MAE
70/30	User-based	0.978530	0.754748
70/30	Item-based	0.984761	0.761577
75/25	User-based	0.970426	0.749167
75/25	Item-based	0.980674	0.759564
80/20	User-based	0.972262	0.750189
80/20	Item-based	0.983170	0.762194

Megállapítás: A user-based módszer minden esetben kisebb hibát adott.

Eredmények (Precision / Recall)

Ajánlási minőség



Train	Módszer	Precision@10	Recall@10
70/30	User-based	0.618033	0.581367
70/30	Item-based	0.540000	0.545085
75/25	User-based	0.592131	0.622212
75/25	Item-based	0.520164	0.584510
80/20	User-based	0.555410	0.674679
80/20	Item-based	0.491311	0.639720

Megállapítás: A user-based modell relevánsabb ajánlásokat adott.

Eredmények értelmezése

Miért jobb a user-based modell?

- jobban felismeri közös ízlést
- hatékonyabb preferencia-mintázat felismerés
- kis/közepes adathalmaznál előnyös

Mikor lehet jobb az item-based?

- nagy rendszereknél
- gyorsabb számítás
- stabilabb film-hasonlóság

A kutatás korlátai

- csak egy adatkészlet
- klasszikus módszerek
- nincs deep learning
- nincs valós felhasználói teszt

További lehetőségek

- Hibrid ajánlórendszer
- Mátrixfaktorizáció
- Deep learning modellek
- Tartalom alapú ajánlás bevonása
- Valós idejű rendszer

Összegzés

Következtetés

A **felhasználó-alapú kollaboratív szűrés** teljesített jobban.

A legjobb pontosság:
75/25 split

A legjobb Recall: 80/20 split

Fő tanulság:

Az adatfelosztás és algoritmusválasztás kritikus az ajánlórendszerek sikerében.

Köszönjük a figyelmet!